



Développement d'un Système d'Irrigation Intelligent et Autonome pour les Pivots Agricoles en Algérie

Binôme

Yazi Lynda Mellissa
Benmachiche Khaled

Résumé

Ce rapport présente un projet de développement d'un système d'irrigation intelligent et autonome destiné à optimiser l'utilisation de l'eau dans les régions désertiques d'Algérie. L'objectif principal est d'améliorer l'efficacité de l'irrigation tout en minimisant le gaspillage d'eau, dans un contexte où les ressources en eau sont limitées et les conditions climatiques particulièrement arides.

La démarche adoptée repose sur l'intégration des techniques d'intelligence artificielle (IA), notamment les réseaux neuronaux et les algorithmes de machine learning, pour adapter en temps réel l'irrigation aux besoins spécifiques des cultures. Ces algorithmes prendront en compte les caractéristiques du sol, les prévisions météorologiques locales et les besoins des différentes cultures afin d'ajuster précisément la quantité d'eau délivrée. Ce système d'irrigation permet ainsi de maximiser les rendements agricoles tout en réduisant l'utilisation d'eau. En outre, la solution proposée est économiquement viable et durable, offrant une réponse adaptée aux conditions climatiques extrêmes des régions désertiques.

Table des matières

Introduction

Contexte

Problématique

Objectifs du Projet

Contexte Climatique et Caractéristiques du Sahara

Description des Conditions Environnementales

Importance de l'Adaptation des Techniques d'Irrigation

Technique Ciblée : Système d'irrigation à pivot central

Présentation des Pivots Agricoles

Étude de Marché

Étude de Cas sur un Site au Portugal : Optimisation de l'Irrigation avec un Modèle d'Apprentissage par Renforcement Profond

Résumé

Approche Technique

a) Modèles LSTM:

Modèle 1 : Prédiction de la teneur en eau du sol (SWTD) à un jour à l'avance

Modèle 2 : Prédiction des rendements des tomates à la fin de la saison

b) Développement de l'agent DQN

Méthodologies

Composantes clés des LSTM :

Comparaison et justification de l'approche suivie

1. Méthodes fixes

2. Méthodes basées sur seuils

3. Réseau de neurones artificiels (ANN)

4. Réseau neuronal convolutif (CNN)

Adaptation du projet au Sahara Algerien

Choix de la Localisation : El Oued, Algérie

Choix de la culture : Tomate

Gestion de l'irrigation

Simulation et Modélisation

Données Disponibles et Contraintes

Recours à NASA POWER pour Combler les Lacunes Climatiques

Calculs Climatiques

Simulation Agro-Climatique Avec DSSAT

Modèles Déployés et Explications Techniques

LSTM 1

LSTM 2

Agent DQN

Résultats Attendus et Perspectives

Résultats Préliminaires

Perspectives d'Amélioration

Conclusion

Références

Introduction

Contexte

Les régions désertiques, avec leurs ressources hydriques limitées et leurs conditions climatiques extrêmes, représentent un défi majeur pour l'agriculture. La mise en place d'un système d'irrigation innovant et durable peut transformer ces contraintes en opportunités. En exploitant des technologies avancées telles que les réseaux neuronaux et les algorithmes de machine learning, le projet permettra de prédire les besoins en eau en fonction de données collectées, comme les prévisions météorologiques et les caractéristiques des cultures.

Le système ajuste en temps réel la distribution de l'eau selon les recommandations générées par les modèles d'IA. Cette approche garantit une meilleure gestion des ressources et une optimisation des rendements agricoles, tout en étant adaptée aux spécificités des pivots utilisés dans les zones désertiques.

Problématique

Comment concevoir un système d'irrigation intelligent et autonome qui maximise l'efficacité de l'utilisation de l'eau tout en s'adaptant aux contraintes des régions désertiques et en répondant aux besoins spécifiques des cultures agricoles ?

Objectifs du Projet

1. Optimiser l'utilisation de l'eau

Le système analysera en continu les conditions climatiques et les caractéristiques du sol pour ajuster précisément la quantité d'eau délivrée, réduisant ainsi le gaspillage.

2. Améliorer les rendements agricoles

Une irrigation adaptée permettra aux cultures de croître dans des conditions optimales, limitant les risques de stress hydrique et favorisant la santé des plantes.

3. Offrir une solution durable et adaptée

Ce projet vise à proposer une solution économiquement viable pour les agriculteurs, contribuant à la pérennité des ressources en eau et réduisant les coûts d'irrigation.

En résumé, ce projet représente une avancée significative pour une agriculture durable et résiliente face aux défis climatiques.

Contexte Climatique et Caractéristiques du Sahara

Description des Conditions Environnementales

Le climat saharien se caractérise par :

- **Températures extrêmes** : Les maximales atteignent 51°C en été, et les minimales peuvent descendre jusqu'à -8°C en hiver.
- **Précipitations faibles** : Elles varient de 0 à 50 mm annuellement, souvent irrégulières.
- **Évapotranspiration élevée** : En moyenne, 50 % de l'évapotranspiration annuelle se concentre entre mai et août.
- **Vent** : Les vents dominants varient en fonction des régions, soufflant généralement du Nord-Est, du Nord-Ouest, de l'Est et du Sud-Ouest, selon les zones.

Les ressources en eau du Sahara algérien sont principalement souterraines, sous forme de nappes phréatiques qui sont essentielles pour l'irrigation et la vie dans cette région aride.

- **Nappe du Continental Intercalaire** : Située de Bechar à Gabès, elle est composée de sables et d'argiles. Profondeur.
- **Nappe du Complexe Terminal** : Nourrit de nombreuses palmeraies, principalement dans le bassin oriental.
- **Nappe de la Djeffara** : Localisée autour du M'zab, mais cette ressource est actuellement surexploitée.

Les sols sahariens sont généralement peu fertiles et présentent une grande hétérogénéité en raison du climat désertique chaud et sec. Ils se caractérisent par une décomposition mécanique des roches (due aux variations de température) et une corrosion éolienne qui trie les particules fines. Ils sont caractérisés par des accumulations de sels (notamment de gypse et de sels solubles) dues à l'évapotranspiration élevée mais sont pauvres en nutriments essentiels comme l'azote et le phosphore.

Importance de l'Adaptation des Techniques d'Irrigation

Compte tenu des contraintes climatiques et géologiques, des solutions innovantes d'irrigation sont nécessaires pour :

- Optimiser l'utilisation de l'eau.
- Maintenir la productivité agricole.
- Réduire les impacts environnementaux tels que la salinisation des sols.

Technique Ciblée : Système d'irrigation à pivot central

Présentation des Pivots Agricoles

Le système d'irrigation à pivot central est conçu pour arroser de grandes surfaces de manière efficace. Il fonctionne grâce à un pivot central alimenté en eau sous pression, qui distribue l'eau à travers des tubes et des asperseurs répartis sur des structures métalliques. Le système tourne lentement autour du pivot, arrosant une grande zone circulaire. Il peut s'adapter aux terrains inclinés et offre un contrôle automatisé dans les modèles modernes.



Figure 1 : Système d'irrigation à pivot Central - El Oued

Avantages

- **Efficacité** : L'eau est répartie de manière uniforme, réduisant les pertes et optimisant l'utilisation de l'eau.
- **Adaptabilité** : Peut fonctionner sur des terrains accidentés ou en pente.
- **Polyvalence** : Convient à différents types de cultures et de climats.
- **Grande couverture** : Irrigue des surfaces de 1 à 75 hectares.

Inconvénients

- **Coût élevé** : L'achat et l'installation du système représentent un investissement important.
- **Sensibilité au vent** : Le vent peut perturber la distribution de l'eau.
- **Limitation géométrique** : Moins efficace sur des champs non circulaires (rectangulaires ou carrés).
- **Consommation d'énergie** : Les moteurs nécessaires pour la rotation augmentent la consommation d'énergie.

Objectif Principal

Intégrer des modèles d'intelligence artificielle (IA) pour améliorer :

- L'efficacité de l'irrigation.
- L'adaptabilité aux conditions locales.

Étude de Marché

Étude de Cas sur un Site au Portugal : Optimisation de l'Irrigation avec un Modèle d'Apprentissage par Renforcement Profond

Résumé

Cet article se concentre sur l'optimisation de l'irrigation agricole grâce à un modèle d'apprentissage par renforcement profond, plus précisément un réseau Q profond (Deep Q-Network, DQN). L'étude de cas se base sur un champ de tomates au Portugal. Environ 70 % des ressources en eau dans l'agriculture sont utilisées pour l'irrigation, ce qui souligne l'importance d'une gestion efficace de l'eau pour préserver les ressources naturelles tout en maintenant la productivité agricole.

L'objectif principal était de développer une stratégie d'irrigation intelligente, combinant des modèles prédictifs et une prise de décision optimisée pour :

- Prédire les besoins en irrigation en fonction des conditions climatiques.
- Maximiser les rendements tout en minimisant la consommation d'eau.
- S'adapter aux variations des conditions climatiques et de l'état du sol.

Approche Technique

1) Collecte des données et leurs prétraitements:

Les auteurs ont recueilli des données climatiques de la région de Fadagosa au Portugal (2010-2020) incluant :

- **Données climatiques** : Température moyenne (TAvg), humidité relative moyenne (HRAvg), vitesse moyenne du vent (WSAvg), précipitations (Prec), évapotranspiration de référence (ETo).
- **Données du sol**: Teneur en eau du sol (SWTD)
- **Rendement des cultures** : Quantité de tomates récoltées (y).

En ce qui concerne la source des données, la majorité provient des stations météorologiques locales, telles que celles de DRAP-Centro. Pour certaines variables spécifiques, notamment la teneur en eau du sol (SWTD), des données simulées ont été générées à l'aide de DSSAT (Decision Support System for Agrotechnology Transfer). Ce système permet d'enrichir les ensembles de données réelles ou de combler les lacunes dans les observations, en simulant des rendements (y) et des valeurs de SWTD sous différents scénarios d'irrigation.

Ces simulations créent des séquences temporelles essentielles pour entraîner les modèles BLSTM à identifier des relations complexes et à améliorer la précision des prévisions sur le long terme.

Les données sont d'abord normalisées et filtrées avant leur utilisation dans les modèles. Les valeurs manquantes sont remplacées par une moyenne mobile, tandis que les variables fortement corrélées sont éliminées à l'aide du facteur d'inflation de la variance (VIF), avec un seuil de VIF supérieur à 5. Enfin, une transformation de normalisation est appliquée pour ramener les variables dans la plage [0, 1].

$$y = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Le résultat est un jeu de données propre et prêt pour l'entraînement des modèles LSTM.

2) Développement des modèles :

a) Modèles LSTM:

Deux modèles LSTM distincts ont été développés, chacun ayant une fonction spécifique, visant à prédire des variables cruciales pour la gestion de l'irrigation et des rendements agricoles. Deux fonctions de perte utilisées :

- Erreur quadratique moyenne (RMSE) pour évaluer la précision des prédictions.

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (y_i - y'_i)^2}{n}}$$

- Coefficient de détermination (R^2) pour mesurer la qualité des prédictions et leur capacité à expliquer la variabilité des données.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - y'_i)^2}{\sum_{i=1}^n (y_i - \widehat{y}_i)^2}$$

Modèle 1 : Prédiction de la teneur en eau du sol (SWTD) à un jour à l'avance

Ce modèle utilise des séries temporelles de données climatiques pour prédire la teneur en eau du sol (SWTD) pour le jour suivant, en fonction des conditions climatiques actuelles.

- Inputs : TAv, HRAvg, WSAvg, Prec, ETo, et les valeurs passées de SWTD.
- Fenêtre temporelle : 4 jours (historique des données).
- Sortie : Prédiction de SWTD pour le jour suivant (SWTDt+1).
- Le modèle démontre une haute précision pour prédire l'état futur du sol. ($R^2 = 0,98$ - RMSE = 6,84 mm).

La prédiction de SWTDt+1 est utilisée par l'agent DQN pour évaluer l'état du sol après une action d'irrigation, facilitant ainsi la simulation des effets des décisions d'irrigation.

Modèle 2 : Prédiction des rendements des tomates à la fin de la saison

Ce modèle estime le rendement des tomates en fonction des données climatiques, de la teneur en eau du sol et de l'irrigation sur toute la saison.

- Inputs : Séries temporelles de données climatiques, SWTD, et historique d'irrigation.

- Fenêtre temporelle : Une saison agricole complète.
- Sortie : Rendement prévu pour la fin de la saison.
- Le modèle fournit des prévisions précises pour estimer les effets à long terme des stratégies d'irrigation. ($R^2 = 0,97$ - RMSE = 366 kg/ha).

Le rendement prédit est utilisé pour calculer la récompense dans le modèle DQN, ce qui permet de relier les décisions d'irrigation à leurs impacts économiques (rendement et coûts).

b) Développement de l'agent DQN

Un réseau neuronal est utilisé pour approximativement apprendre la fonction de valeur Q ($Q(s, a)$), permettant à l'agent de prendre des décisions optimales en matière d'irrigation.

L'objectif est de déterminer les volumes d'irrigation optimaux pour chaque étape temporelle, maximisant la récompense cumulée et minimisant la consommation d'eau.

- **Inputs :**
 - État actuel (st) : Combinaison des paramètres climatiques (TAvg, HRAvg, WSAvg, Prec, ETo), de l'irrigation passée et du SWTD actuel.
 - Rendement (yt).
- **Outputs :**
 - Action optimale (at) : Choix parmi 12 volumes d'irrigation (0 mm à 60 mm par jour).
 - Etat suivant (st+1).

On constate une convergence stable du modèle et performances supérieures aux autres approches ainsi qu'une réduction de 20 à 30 % de la consommation d'eau et une augmentation de 11 % du rendement.

Processus :

- **Calcul de l'état futur :** Le modèle LSTM de SWTD prédit la teneur en eau du sol pour le jour suivant ($SWTD_{t+1}$) en fonction de l'action d'irrigation choisie (at).
- **Calcul de la récompense (rt) :**
La récompense est calculée à l'aide de l'équation suivante :
où : $r = y_p^* - w * p_w$
 - y est le rendement estimé
 - w est la consommation d'eau,
 - p_y et p_w sont respectivement le prix des tomates et le coût de l'eau.
- **Optimisation de la politique (π^*) :**
L'équation de Bellman est utilisée pour exprimer la relation récursive entre la récompense instantanée et la valeur future des états et actions. Cela permet d'ajuster les valeurs de $Q(s, a)$ pour apprendre la politique optimale qui maximisera les récompenses cumulées.

$$Q^{(i)}(s, a) = \sum_{s'} T(s'|s; a) [R(s; a; s') + \gamma \max_{a'} Q^{(i-1)}(s', a')]$$

$$\lim_{i \rightarrow \infty} Q^{(i)}(s, a) = Q^*(s, a)$$

La récompense cumulée R_t est la somme des récompenses futures actualisées par un facteur de discount γ (pondérant l'importance des récompenses futures):

$$R_t = \sum_{i=0}^T \gamma^i r_{t+i}$$

La **fonction de perte** est utilisée pour ajuster les paramètres du modèle (notamment le modèle LSTM et la politique) afin de minimiser l'écart entre les prédictions et les valeurs réelles ou attendues.

$$L(\theta) = ((r(s_t, a_t, s_{t+1}) + \gamma \cdot \max_{a_{t+1}} \hat{Q}(s_{t+1}, a_{t+1}, \hat{\theta}) - Q(s_t, a_t; \theta))^2$$

- **Stabilité de l'entraînement :**

Pour stabiliser l'apprentissage du modèle de reinforcement learning (tel que DQN), un réseau cible est utilisé. Ce réseau est une copie du réseau principal, mais mise à jour moins fréquemment pour réduire la variance des estimations et améliorer la stabilité.

- **Mise à jour des poids :**

Les poids du réseau cible sont mis à jour avec une fréquence inférieure à celle du réseau principal pour garantir la stabilité de l'entraînement.

$$\hat{\theta} = \tau \theta + (1 - \tau) \hat{\theta}$$

- **Validation et comparaison des performances**

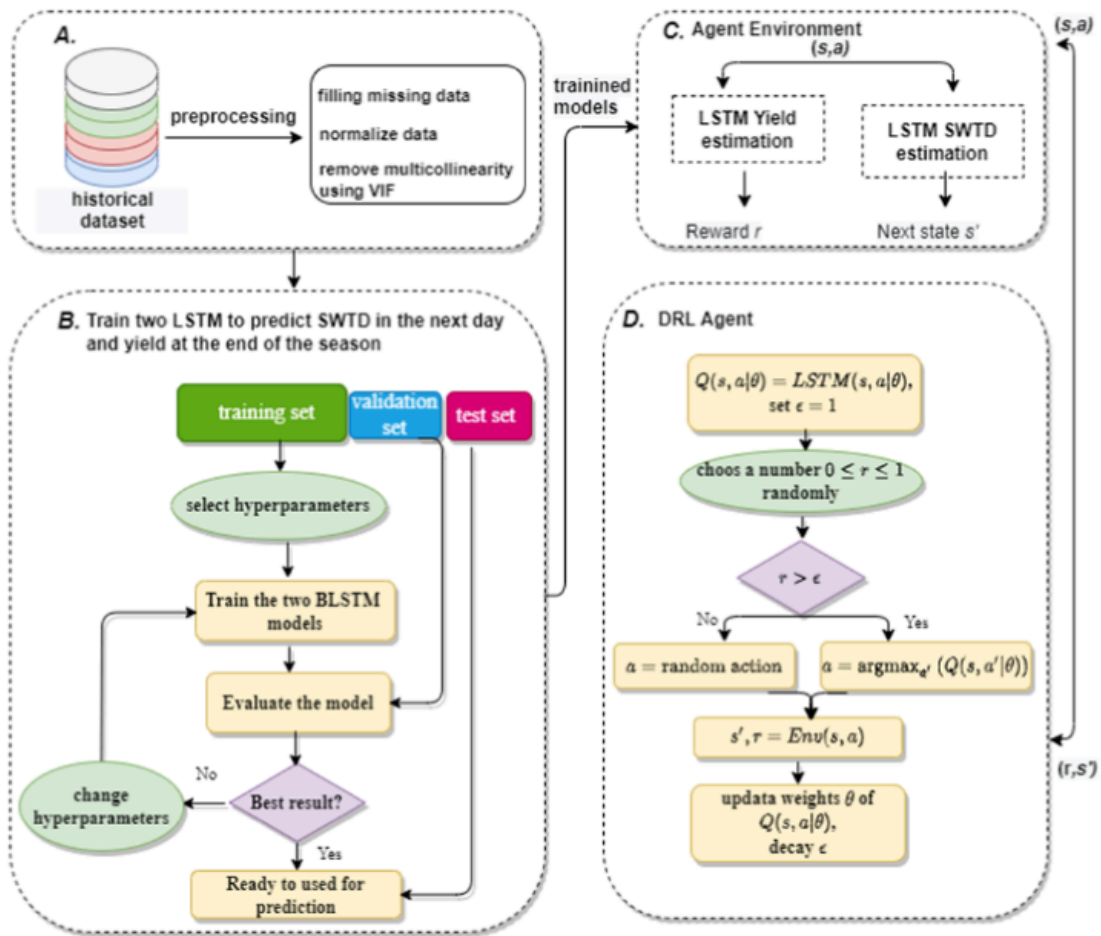


Figure 2 : Schéma récapitulatif des approches techniques utilisées

Méthodologies

La question qu'on peut se poser est : pourquoi ce choix de technologies?

1) Pourquoi choisir un LSTM pour les séries temporelles ?

Les LSTM (Long Short-Term Memory) sont un type de réseau neuronal récurrent qui est particulièrement efficace pour traiter des séries temporelles complexes, comme les données climatiques et la teneur en eau du sol. Ils sont utilisés pour les séries temporelles en raison de leur capacité à gérer des **dépendances à long terme**. Contrairement aux RNN classiques, les LSTM utilisent des **portes** (oubli, entrée, sortie) qui régulent le flux d'informations à travers le temps, ce qui permet de mémoriser et d'actualiser les informations importantes tout en oubliant celles qui ne le sont pas.

Composantes clés des LSTM :

1. **Porte d'oubli (Forget Gate)** : Décide des informations à oublier.
2. **Porte d'entrée (Input Gate)** : Ajoute de nouvelles informations à la mémoire.
3. **Mise à jour de l'état cellulaire** : Combine l'ancienne et la nouvelle information.

4. **Porte de sortie (Output Gate)** : Produit la sortie de la cellule, qui est utilisée pour la prédiction.

Les LSTM sont particulièrement efficaces pour les prévisions de séries temporelles, comme la **prédiction de la teneur en eau du sol** ou du **rendement agricole**, car ils peuvent capturer des relations complexes et des dépendances temporelles. D'autres modèles traditionnels ne parviennent pas à gérer ces dépendances à long terme, d'où l'utilisation des LSTM pour obtenir de meilleurs résultats.

2) Pourquoi DQN ?

Le DQN est utilisé pour résoudre des problèmes séquentiels où un agent apprend une stratégie (π^*) qui maximise les bénéfices sur le long terme. Le DQN est adapté pour gérer des problèmes séquentiels où les actions influencent les résultats futurs. Contrairement aux méthodes à seuil ou fixes, il s'adapte aux variations climatiques.

Comparaison et justification de l'approche suivie

Pour expliquer pourquoi nous avons suivi la démarche actuelle dans l'étude d'irrigation, il est important de comparer notre approche basée sur le modèle d'Apprentissage Par Renforcement (DQN) avec d'autres méthodes classiques et d'intelligence artificielle, en mettant en lumière les avantages et les raisons de nos choix.

1. Méthodes fixes

C'est l'irrigation basée sur un volume fixe d'eau appliqué à intervalles réguliers, sans ajustement selon les conditions climatiques ou l'état du sol.

Inconvénients :

- **Non-adaptatif** : Cette méthode ne prend pas en compte les variations des besoins en eau selon le climat ou le stade de croissance des plantes. Cela peut entraîner un gaspillage d'eau ou un stress hydrique, affectant la croissance et le rendement.
- **Inefficacité** : Les rendements sont souvent inférieurs à ceux obtenus avec des approches plus dynamiques comme celles de l'IA.

Pourquoi ne pas l'avoir suivi :

Les méthodes fixes ne permettent pas d'optimiser l'irrigation en fonction des besoins réels des plantes. En utilisant l'IA et l'apprentissage par renforcement, nous avons cherché à ajuster l'irrigation en temps réel en fonction des données climatiques et de l'état du sol, ce qui permet une meilleure gestion de l'eau et des rendements.

2. Méthodes basées sur seuils

L'irrigation est déclenchée lorsque la teneur en eau du sol (SWTD) atteint un seuil prédéfini (ex : $SWTD < 440$).

Inconvénients :

- **Réglage délicat des seuils** : Les seuils peuvent ne pas être adaptés à toutes les situations climatiques ou de sol, entraînant soit un gaspillage d'eau, soit un manque d'irrigation.
- **Consommation d'eau élevée** : Pour des rendements similaires à ceux du modèle DQN, la consommation d'eau est supérieure de 35 %.

Pourquoi ne pas l'avoir suivi :

Bien que plus flexible que la méthode fixe, l'irrigation par seuil reste limitée, car elle nécessite un ajustement précis des seuils qui peut être difficile à réaliser. Le modèle DQN permet d'adapter l'irrigation de manière continue et dynamique, maximisant à la fois l'efficacité de l'utilisation de l'eau et les rendements.

3. Réseau de neurones artificiels (ANN)

Dans l'article, ils ont également tenté d'utiliser un réseau de neurones pour prédire les volumes d'irrigation optimaux à partir des données climatiques, de la teneur en eau du sol, et de l'historique d'irrigation.

Inconvénients :

- **Absence de prise en compte des relations temporelles** : Les ANN ne sont pas efficaces pour traiter des séries temporelles complexes.
- **Convergence instable** : L'apprentissage peut être lent et ne converge pas toujours correctement dans des contextes temporels comme l'irrigation.

Résultats comparatifs :

- L'ANN a montré des résultats moins efficaces que le modèle DQN, avec une diminution des récompenses moyennes pendant l'entraînement. L'ANN n'est donc pas capable de saisir les dynamiques temporelles complexes comme le fait un modèle LSTM (Long Short-Term Memory).

4. Réseau neuronal convolutif (CNN)

Le CNN extrait des caractéristiques complexes à partir des données climatiques et de l'état du sol pour estimer les volumes d'irrigation.

Inconvénients :

- **Inadapté aux séries temporelles** : Bien que puissant pour traiter des données spatiales (comme des images satellites), un CNN est moins adapté aux séries temporelles complexes où les relations entre les données sont dynamiques.

- **Coût computationnel élevé** : Le CNN est plus coûteux en termes de calculs par rapport aux modèles LSTM.

Résultats comparatifs :

- Le CNN n'a pas convergé correctement et a produit des récompenses moyennes inférieures à celles du modèle DQN avec LSTM. Bien que le CNN soit efficace pour des données spatiales, il ne capture pas bien les relations temporelles entre les données climatiques et de sol sur plusieurs périodes.

Conclusion

En comparant toutes les méthodes, il est évident que l'utilisation d'un modèle DQN avec LSTM est la plus adaptée pour gérer l'irrigation de manière efficace. Contrairement aux méthodes fixes et basées sur seuils, notre approche dynamique permet de maximiser les rendements tout en réduisant la consommation d'eau. De plus, l'utilisation d'ANN et de CNN, bien que puissantes dans certains domaines, ne répond pas aux besoins spécifiques des séries temporelles complexes dans ce contexte particulier. Le choix du modèle DQN-LSTM a donc été justifié par sa capacité à traiter les dépendances temporelles et à s'adapter aux besoins réels des plantes en temps réel.

Cette approche a permis de

- Réduire la consommation d'eau de 20-30 % par rapport aux méthodes fixes.
- Améliorer la productivité de 11 %.
- Éviter le gaspillage d'eau en début de saison et minimiser le stress hydrique en fin de saison.

Cependant, l'utilisation de modèles nécessitant des données simulées spécifiques au contexte local (type de sol, climat, culture) reste une limitation. Cette étude démontre le potentiel de l'intelligence artificielle pour optimiser l'irrigation et contribuer à une gestion plus durable des ressources en eau dans l'agriculture.

Adaptation du projet au Sahara Algerien

Choix de la Localisation : El Oued, Algérie

La région d'El Oued (**Coordonnées** : Latitude : 33.3678°N, Longitude : 6.8517°E.), située dans le sud-est de l'Algérie, a été choisie pour cette étude. Sa spécificité réside dans l'adaptation des cultures à un environnement difficile, ce qui en fait un lieu pertinent pour tester des solutions innovantes comme les systèmes d'irrigation intelligents. El Oued présente un sol sableux, riche en silice, adapté aux conditions arides mais avec des défis majeurs : une perméabilité élevée et une faible capacité de rétention d'eau, une faible teneur en matière organique et une salinisation importante, réduisant l'absorption des nutriments et la productivité des cultures. Le climat est désertique chaud (Köppen BWh), avec des températures estivales souvent supérieures à 40°C, des précipitations annuelles très

faibles (<50 mm) et une évapotranspiration élevée, nécessitant une gestion rigoureuse de l'irrigation pour soutenir les cultures.




Figure 3 : Wilaya d'El-Oued

Choix de la culture : Tomate

Les variétés de tomates sélectionnées pour la région d'El Oued comprennent : *Salima*, *Petra*, *Mercur*, *Aya*, *Maysaloun*, et *Farida*. Ces variétés sont adaptées aux conditions climatiques et aux caractéristiques du sol de la région, notamment aux températures élevées et à la faible disponibilité en eau.

- **Méthode de plantation adaptée au sol :** Semis direct pour protéger contre les vents chauds.
- **Espacement des plantes :** 50 à 70 cm entre les plantes, 1 et 1,5 mètre entre les lignes (optimisé pour le pivot).
- **Date de récolte :** 70-90 jours après plantation.

Gestion de l'irrigation

Avant la plantation, il est conseillé d'irriguer le sol afin d'atteindre 75-80 % de la capacité au champ, avec une irrigation localisée pour uniformiser l'humidité. La méthode du pivot mobile est idéale, car elle permet une couverture homogène des parcelles, réduit le gaspillage d'eau et atteint des zones difficiles d'accès tout en maintenant une pression d'eau adéquate. Un plan d'irrigation efficace prévoit des arrosages réguliers tous les 3 à 7 jours, avec une durée variant entre 30 minutes et 1 heure selon le système utilisé, tel que l'irrigation goutte-à-goutte ou les pivots mobiles. Il est crucial que l'irrigation atteigne une profondeur de 30 à 45 cm, afin d'assurer que les racines des tomates reçoivent suffisamment d'eau, surtout dans des sols arides où l'humidité s'évapore rapidement.

Simulation et Modélisation

Données Disponibles et Contraintes

Les données spécifiques sur les sols, le climat et les rendements agricoles sont rares ou peu accessibles. Cela peut être dû à :

- **Manque d'infrastructure de collecte de données locales** : Les réseaux de stations météorologiques et les études pédologiques à grande échelle sont encore insuffisants dans de nombreuses régions rurales, particulièrement dans les zones désertiques comme El Oued.
- **Absence de mise à jour régulière des données** : Les données disponibles sont souvent anciennes et ne tiennent pas compte des changements climatiques récents ou des pratiques agricoles modernes.

Recours à NASA POWER pour Combler les Lacunes Climatiques

Le **NASA POWER** (Prediction Of Worldwide Energy Resources) est une ressource en ligne fournissant des informations météorologiques et climatiques adaptées aux besoins de l'agriculture, de l'énergie, et de la recherche scientifique. Ces données proviennent d'un mélange d'observations satellitaires et de mesures au sol, collectées par des satellites.




Figure 4 : NASA POWER Site

Nous avons spécifié les conditions nécessaires pour obtenir les données climatiques de la NASA en indiquant les paramètres suivants : les coordonnées géographiques (latitude et longitude), la période temporelle (année et jour de l'année), le niveau temporel souhaité (quotidien, horaire, etc.), ainsi que l'étendue géographique pertinente. Ainsi que différents paramètres climatiques tels que : la température de l'air à 2 mètres) ou encore l'humidité spécifique à 2 mètres, nécessaires pour notre étude.





Figure 5: Configuration des paramètres sur NASA POWER Site

Ces données de la NASA, couvrant jusqu'à 24 ans, sont d'une grande utilité pour simuler les conditions climatiques à long terme et estimer les besoins en eau pour l'agriculture dans la région d'El Oued.

Calculs Climatiques

Une étape clé consiste à calculer l'évapotranspiration de référence (ET_o) à l'aide de l'équation de Penman-Monteith. L'ET_o est une mesure importante pour l'agriculture, car elle permet d'estimer la quantité d'eau nécessaire pour répondre aux besoins en évaporation et en transpiration des cultures.

$$ET_o = \frac{0.408 \times \Delta \times (R_n - G) + \gamma \times \left(\frac{900}{T + 273} \right) \times U_2 \times (e_s - e_a)}{\Delta + \gamma \times (1 + 0.34 \times U_2)}$$

Δ est la pente de la courbe de pression de vapeur saturante,

R_n est le rayonnement net

G est la densité de flux thermique dans le sol

γ est la constante psychrométrique,

U_2 est la vitesse du vent à 2 mètres

e_s est la pression de vapeur saturante

e_a est la pression de vapeur réelle

Simulation Agro-Climatique Avec DSSAT

Le **DSSAT (Decision Support System for Agrotechnology Transfer)** est un logiciel complet conçu pour simuler la croissance des cultures, les processus du sol et l'impact des pratiques agricoles dans différentes conditions environnementales. Il utilise des modèles mécanistes pour prédire les rendements agricoles, l'utilisation de l'eau, et les dynamiques des nutriments, permettant ainsi de prendre des décisions agricoles basées sur des données.

En Python, la bibliothèque **DSSATTools** offre une interface pour intégrer les simulations de DSSAT. Elle permet de définir des scénarios météorologiques, de sol y compris des détails comme l'utilisation d'engrais, de culture et de gestion directement dans un environnement Python. Cela simplifie la configuration et l'exécution des simulations, tout en facilitant l'analyse avancée des données et l'automatisation des tâches.

Le modèle choisi pour la simulation des cultures est le modèle de culture "CROPGRO-Tomato", qui permet de simuler les rendements des tomates en prenant en compte des variables :

- **Conditions climatiques** : Les données météorologiques sont transformées en un format adapté à la simulation.
- **Profil de sol** : Les propriétés du sol, comme sa texture et sa capacité de rétention d'eau, sont configurées.
- **Cultures agricoles** : Les caractéristiques des cultures (par exemple, la tomate) sont définies pour chaque simulation.

- **Gestion agricole** : Des pratiques agricoles comme l'irrigation et la fertilisation sont paramétrées.

La sortie du modèle inclut des indicateurs essentiels pour la gestion de l'irrigation, tels que l'IRRC (irrigation requise), le SWDT (teneur du sol en eau) et le CWAD (poids de la culture). Ces paramètres sont utilisés pour optimiser les stratégies d'irrigation et mieux comprendre l'impact des conditions climatiques sur la productivité des cultures.

Deux jeux de données principaux sont créés pour l'entraînement de modèles prédictifs :

1. **Data1** : Inclut des variables climatiques et la teneur du sol en eau pour évaluer l'impact des conditions météorologiques sur le sol.
2. **Data2** : Combine les données de croissance des plantes avec celles du climat et du sol pour une analyse plus complète des interactions environnementales.




Figure 7 : Répartition des variables récoltées / simulées.

Modèles Déployés et Explications Techniques

LSTM 1

A noter que pour le LSTM 1, c'est un code préexistant qui a été utilisé directement adapté pour obtenir de bons résultats via des hyperparamètres soigneusement choisis.

Après plusieurs essais, nous avons ajusté les paramètres en fixant l'époque et en testant les autres hyperparamètres pour obtenir les meilleurs résultats. Nous avons finalement configuré le modèle afin d'atteindre un score R^2 supérieur à 0,9.

Le processus de prétraitement des données a débuté par le nettoyage des données de la variable *Data1*, avec la suppression des valeurs manquantes et la gestion des valeurs aberrantes à l'aide du Z-score. Pour stabiliser la variance et accélérer la convergence, les colonnes numériques ont été normalisées à l'aide de *StandardScaler*. Les données des années 2022 et 2023 ont été utilisées comme ensemble de tests, tandis que les années précédentes ont servi à l'entraînement. La longueur de la séquence utilisée pour préparer les données était de 7 jours.

Le modèle LSTM développé comprenait deux couches bidirectionnelles avec 512 neurones cachés et une fonction d'activation *tanh*. Une régularisation par *dropout* de 30% a été ajoutée pour éviter le surajustement. La couche de sortie est une *Dense* avec un neurone unique, permettant la prédiction du SWTD. Les paramètres d'entraînement incluent l'optimiseur *Adam*, un taux d'apprentissage de 1×10^{-4} et un taux de décroissance de 1×10^{-5} , un *batch size* de 128 et 500 epochs, avec un arrêt anticipé après 20 epochs sans amélioration.

Après l'entraînement, le modèle a atteint un score R^2 de 0,9, ce qui témoigne de sa bonne performance.

Figure 8: Résultats de prédiction du LSTM 1

LSTM 2

Pour le modèle LSTM2, une analyse approfondie des données a été réalisée, suivie de modifications dans l'architecture afin d'améliorer les performances.

Une analyse exploratoire des données a permis d'identifier les relations entre les variables à travers une analyse de corrélation. De nouvelles caractéristiques ont été créées, telles que l'interaction entre *PREC* et *SWTD* (colonne *PREC_SWXD*) ainsi qu'entre *IRRC* et *SWTD* (colonne *IRRC_SWTD*).



Une réduction dimensionnelle a été effectuée à l'aide de l'analyse en composantes principales (PCA), permettant de conserver 95% de la variance tout en réduisant le nombre de dimensions.

Les hyperparamètres ont également été ajustés, avec un *seq_len* de 110 pour prendre en compte des tendances sur des périodes plus longues, ainsi qu'un taux d'apprentissage de 1×10^{-3} et une séparation des données en ensembles d'entraînement et de test selon un ratio de 80/20 a été faite.

L'architecture du modèle LSTM a été ajustée en ajoutant une deuxième couche LSTM bidirectionnelle pour capturer des dépendances temporelles complexes. Chaque couche LSTM est suivie d'un *dropout*

pour la régularisation, et une couche *Dense* intermédiaire avec 128 neurones et activation *tanh* a été incluse.

L'évaluation du modèle a montré un R^2 de 0,91, et les résultats ont été visualisés en comparant les valeurs réelles et prédites, ce qui a permis de mieux comprendre les performances du modèle.






Figure 9: Résultats de prédiction du LSTM2

Agent DQN

a) Pseudo-Algorithme de Environnement:

```

ENV step(state, action):
    state_of_season=[];
    next_SWTD=BLSTM1.predict(state, action);
    state_of_season.append(state, action);
    if time_step = length_of_a_Season then
        Done=True;
        Y=BLSTM2.Predict(states_of_season);
        compute net return using Equation (10);
    else
        Done=False;
        net return=0;
    time_step+=1;
    return next_SWTD, net return, done
  
```

Le processus commence par l'initialisation de `state_of_season`, un tableau servant de mémoire pour collecter les états tout au long de la saison. À chaque étape, le modèle BLSTM1 prédit le prochain état (`next_SWTD`) en fonction de l'état actuel (`state`) et de l'action entreprise (`action`),

comme l'irrigation appliquée. La prédiction est ajoutée au tableau pour suivre l'évolution. Lorsque le pas de temps atteint la durée de la saison, les états accumulés sont transmis au modèle BLSTM2 pour prédire le rendement total, et le retour net est calculé. Sinon, la saison continue, avec une mise à jour du temps et un retour net temporairement nul.

b) Pseudo-Algorithmme d'apprentissage par renforcement:

```

initialize reply memory D ;
initialize training environment env=LSTM();
randomly initialize Action-Value function Q with weight  $\theta$ ;
randomly initialize target Action-Value function  $\hat{Q}$  with weight  $\hat{\theta} = \theta$ ;
for episode=1 to max_episode do
    Done=False;
    while Done=False do
        random = random_uniform(0, 1);
        if epsilon < random then
            | action = random.choice(0, number_of_actions);
        else
            | action = argmaxa(Q(current_state, a;  $\theta$ ));
        end
        next_SWTD, reward, Done=env(current_state, action);
        next_state=Concatenate(next_SWTD, next_climate_data);
        store transition (current_state, action, reward, next_state, Done) in D;
        sample random batch of transitions from D;
        set:

$$y_j = \begin{cases} \text{reward} & \text{if } Done = True, \\ \text{reward} + \gamma \max_a \hat{Q}(next\_state, a; \hat{\theta}) & \text{Otherwise;} \end{cases}$$

        do a single gradient step on  $(y_j - Q(s_j, a_j; \theta))^2$  w.r.t  $\theta$ ;
        updat the weights of  $\hat{Q}$  using equation (8);
        current_state=new_state
    end
end

```

L'algorithme débute par l'initialisation d'une mémoire de réplique D, qui stocke les transitions (état, action, récompense, état suivant, terminalité) pour stabiliser l'apprentissage via des échantillons diversifiés. L'environnement d'entraînement est basé sur un modèle LSTM, et la fonction Q est initialisée avec des poids aléatoires θ , tandis qu'une fonction cible $\hat{Q}$ est également configurée pour renforcer la stabilité. Dans chaque épisode, une stratégie ϵ -greedy est utilisée pour choisir une action, alternant entre exploration aléatoire et exploitation des connaissances actuelles. Les transitions collectées sont stockées dans D et utilisées pour entraîner le réseau Q via des mini-lots. Les cibles sont calculées selon un facteur d'actualisation, et les poids sont optimisés par descente de gradient, avec une mise à jour périodique de $\hat{Q}$. Enfin, l'état suivant devient l'état actuel pour continuer le processus.

Résultats Attendus et Perspectives

Résultats Préliminaires

Les modèles LSTM développés dans cette étude ont produit des résultats encourageants :

1. Réduction des volumes d'eau utilisés :

Les prédictions précises de l'humidité du sol ($R^2=0.9$ pour LSTM1) permettent des ajustements dynamiques de l'irrigation, évitant ainsi un gaspillage d'eau.

2. Amélioration des rendements agricoles :

Grâce à une irrigation adaptée et prédite par LSTM2 ($R^2=0.93$), les cultures bénéficient d'une croissance optimale. La production agricole est maximisée tout en maintenant un usage durable des ressources.

Perspectives d'Amélioration

Pour renforcer l'efficacité des modèles et leur impact, plusieurs pistes d'amélioration sont envisagées :

1. Enrichissement des données :

Collecte continue des données sur plusieurs saisons pour affiner les modèles et capturer des dynamiques temporelles plus riches.

2. Partenariats locaux :

Collaboration avec des agriculteurs pour tester le système en conditions réelles et évaluer son efficacité sur le terrain et avoir ainsi un recueil des retours d'expérience pour ajuster les modèles et adapter les recommandations aux contraintes pratiques.

3. Surveillance continue :

Mise en place d'un suivi régulier de la qualité des sols et des eaux pour prévenir la dégradation des ressources, notamment dans les zones à forte exploitation agricole.

4. Partenariats locaux :

En dehors des aspects purement techniques liés, des consultations avec des agriculteurs ont permis d'identifier des pratiques clés pour améliorer durablement la production agricole tout en préservant les sols et les ressources en eau. Ces propositions tiennent compte des réalités du terrain et des retours des praticiens.

- **Technique de lessivage (drainage des sels accumulés) :** Utilisation d'eau douce pour laver les sols et réduire les concentrations en sel, un facteur critique dans les régions sujettes à la salinisation.

- **Restauration de la matière organique :** Ajout de compost, de fumier ou d'amendements spécifiques pour augmenter la rétention d'eau et de nutriments dans les sols.
- **Engrais spécifiques :** Utilisation d'engrais adaptés aux cultures locales et aux conditions pédologiques pour stimuler la croissance sans surcharger le sol en éléments indésirables.
- **Variétés hybrides résistantes :** Promotion de variétés comme la Tofane, qui sont reconnues pour leur résistance aux maladies et leur adaptabilité aux conditions climatiques difficiles.

Conclusion

Le projet de système d'irrigation intelligent et autonome représente une avancée majeure dans l'adaptation de l'agriculture aux contraintes climatiques des zones désertiques. En combinant les technologies modernes d'intelligence artificielle et d'irrigation de précision, ce système permettra non seulement d'optimiser l'utilisation des ressources en eau, mais aussi d'améliorer les rendements agricoles de manière durable et économiquement viable. Cette solution offre un modèle pour les agriculteurs des régions arides, leur permettant de faire face aux défis de l'aridité et de contribuer à une gestion plus responsable de l'eau, ressource précieuse dans ces zones.

Voici les liens correspondant à nos travaux :

- **Data Analysis / Simulation** : [Lien vers le notebook](#)
- **LSTM 1 (SWTD)** : [Lien vers le notebook](#)
- **LSTM 2 (Yield Prediction)** : [Lien vers le notebook](#)

Références

1. Berkal Ismaeil - Contribution à la connaissance des sols du Sahara d'Algérie
[Lien vers le document](#)
2. Wikipedia - El Oued [Lien vers la page Wikipedia](#)
3. NASA POWER Project [Lien vers le site de NASA POWER](#)
4. YouTube - StatQuest Channel: LSTM [Lien vers la chaîne YouTube StatQuest](#)
5. Mémoire de Fin d'Étude - Caractérisation de la salinité des sols de la région d'Oued Souf
Présenté par : Chennouf Khemissa, Mokhtari Faiza, Tliba Oualid Badereddine, Zine Abdessamie. [Lien vers le mémoire](#)
6. Mémoire de Fin d'Étude - Enquête sur la situation de la tomate dans la région d'El-Oued [Lien vers le document PDF](#)
Présenté par : Gheraissa Dounia, Askri Amina.
7. [AFKO Algérie - Système d'irrigation à pivot central](#)
8. Irrigation optimization with a deep reinforcement learning model: Case study on a site in Portugal. Auteurs : Khadijeh Alibabaei, Pedro D. Gaspar, Eduardo Assunção, Saeid Alirezazadeh, Tânia M. Lima [Lien vers l'article complet](#)
9. GitHub - DQN irrigation in agriculture [Lien vers le projet GitHub](#)
10. GitHub - Tomato yield estimation [Lien vers le projet GitHub](#)
11. GitHub - Soil Water Content and Reference Evapotranspiration [Lien vers le projet GitHub](#)